

Benchmark Quantum–Classical su Embedding OCT Compressi

Handout operativo — Base condivisa ed esplorazioni controllate

Idea centrale. Il progetto parte da uno **studio comune dello stato dell'arte** e da una **pipeline condivisa fissata** dopo la Week 0. Successivamente i gruppi esplorano in modo controllato variazioni su **encoding quantistico**, **compressione degli embedding** e **ansatz variazionale**, mantenendo fair comparison, modularità del codice e futura integrazione in un'unica pipeline eseguibile. **Base comune fissata.** Immagini a 224×224 , backbone congelato, **PCA** come compressione di riferimento, **sweep comune obbligatorio** sulle dimensioni latenti $\mathcal{D} = \{32, 16, 8, 4\}$, **angle encoding** R_Y con data re-uploading e **RealAmplitudes shallow** come ansatz iniziale.

1 Quadro generale

Voce	Sintesi
Dataset	OCTMNIST , classificazione multiclasse su immagini OCT.
Risoluzione	224x224 come standard della pipeline principale. 28x28 solo come valutazione finale opzionale di compattezza/stress-test.
Backbone comune	Un solo ResNet-18 bloccato per tutti dopo la Week 0. Le feature condivise sono vettori in $\mathbb{R}^{512}$ estratti dopo il global average pooling e prima del layer fully connected finale . Nessun backbone specifico di team.
Pipeline condivisa	Preprocessing comune, backbone congelato, baseline classiche, PCA come compressione di riferimento, sweep comune sulle dimensioni latenti $\mathcal{D} = \{32, 16, 8, 4\}$, angle encoding R_Y con data re-uploading, RealAmplitudes shallow come ansatz baseline, metriche e artifact comuni.
Input comuni	Manifest di train/val/test, embedding congelati, definizioni metriche, subset few-shot, schema degli artifact e regimi latenti condivisi $\mathcal{D} = \{32, 16, 8, 4\}$. Seed clean: 11, 17, 29. Seed few-shot/robustezza: 11, 23.
Ablazione comune	Per ogni $d \in \mathcal{D}$, tutti i team devono eseguire una no-quantum ablation che coincide con il comparatore classico lineare sulle feature compresse, cioè una mappa $\mathbb{R}^d \rightarrow \mathbb{R}^4$ con stesso protocollo di training e stesse metriche del benchmark principale.
Esplorazioni controllate	Tutti i gruppi eseguono prima lo sweep comune su $\mathcal{D} = \{32, 16, 8, 4\}$; solo dopo esplorano rispettivamente variazioni promettenti su encoding, compressione e ansatz, senza ridefinire la pipeline di base.
Confronto classico	Stesso screening per tutti: logistic regression, MLP a un hidden layer, RBF-SVM. La logistic regression coincide con la no-quantum ablation obbligatoria su feature compresse.
Obiettivo	Stimare quale variazione controllata aggiunge più valore rispetto alla base condivisa fissata , senza confondere risultati baseline ed esplorativi.

2 Asset comuni congelati

Per rendere la pipeline sperimentale **verificabile, confrontabile e integrabile** tra i diversi team, i seguenti elementi devono essere comuni, espliciti e stabili:

- **Manifest condivisi:** `train_ids.csv`, `val_ids.csv`, `test_ids.csv`. Definiscono una volta per tutte quali campioni appartengono a train, validation e test, e in quale ordine devono essere letti.

- **Risoluzione standard: 224x224.** È la dimensione di input usata nella pipeline principale, così backbone e confronti restano coerenti tra i gruppi.
- **Test opzionale 28x28: 28x28** è ammesso solo come verifica finale di compattezza o stress-test; non deve sostituire la pipeline primaria né comparire come evidenza principale.
- **Embedding comuni:** un solo pacchetto `resnet18_locked`. Sono vettori in $\mathbb{R}^{512}$ estratti da **ResNet-18 congelato dopo il global average pooling e prima del layer fully connected finale**; tutti i team devono consumare esattamente queste feature come punto di partenza condiviso.
- **Pipeline condivisa fissata:** preprocessing comune, backbone congelato, baseline classiche e protocolli di valutazione condivisi. In pratica, tutti partono dallo stesso flusso minimo prima di aprire variazioni locali.
- **Compressione baseline: PCA** come riferimento lineare, semplice e tracciabile per i primi confronti comuni. Serve come base stabile; autoencoder e varianti learned **unsupervised** si trattano come esplorazioni successive.
- **Regimi latenti comuni:** tutti i team devono eseguire la pipeline principale per $\mathcal{D} = \{32, 16, 8, 4\}$. Lo studio della dimensione latente ridotta fa quindi parte del benchmark comune e non di un solo ramo locale.
- **No-quantum ablation condivisa:** per ogni regime latente, tutti i team devono valutare anche una baseline senza circuito quantistico, che **coincide con il comparatore classico lineare / logistic regression** sulle feature compresse $u \in \mathbb{R}^d$.
- **Policy few-shot condivisa:** seed 11, 23 e frazioni 25%, 10%, 5%. Significa che i subset ridotti di train devono essere costruiti sempre con le stesse regole, così i confronti few-shot restano fair.
- **Formule metriche condivise:** Macro-AUROC, Macro-F1, balanced accuracy, ECE. Tutti devono calcolarle nello stesso modo, con la stessa convenzione di classi e stessi file di output.
- **Quantum encoding baseline:** feature riscalate in $(0, 2\pi]$, **angle encoding** semplice con rotazioni R_Y , identico per tutti i team. Questo impedisce di introdurre una variabile nascosta già al livello di input del circuito.
- **Ansatz baseline: RealAmplitudes shallow** come struttura 2-local semplice e hardware-friendly per i primi run comuni. Le varianti di Team C non sostituiscono la base, ma la estendono in modo controllato.
- **Data re-uploading baseline:** quando $d > n_{\text{qubit}}$, le feature vengono caricate a blocchi sugli stessi qubit. Serve a gestire input più grandi del numero di qubit senza cambiare il significato del confronto.
- **Interfacce modulari dei file .py:** preprocessing, embedding, compressione, encoding, ansatz, training, evaluation e reporting devono avere input/output chiari e compatibili. Questo permette di unire in seguito i moduli in un'unica pipeline eseguibile.
- **Formato comune degli artifact:** compressi, predizioni, metriche e log devono avere naming e campi coerenti. In questo modo ogni risultato è leggibile, verificabile e riusabile da tutti.

3 Contratto di training (obbligatorio e congelato)

Per evitare implementazioni incompatibili del VQC, la seguente procedura è **obbligatoria e identica per tutti i team**.

Componente	Specifica obbligatoria
Output del circuito	Expectation value di osservabili Pauli-Z su ogni qubit
Mappa logit	Linear layer classico: $\mathbb{R}^{n_{qubit}} \rightarrow \mathbb{R}^4$
Loss	Cross-entropy multiclass (4 classi OCTMNIST)
Ottimizzatore*	Adam, learning rate = 0.001
Batch size*	32
Numero epoche*	50
Early stopping*	patience = 7 (validation loss)
Inizializzazione*	Parametri circuitali $\sim \mathcal{U}(-0.01, 0.01)$
Backend	Simulatore statevector (default)
Shots* (Se sampler)	1024
Seed training	11, 17, 29

Nota. Alcuni degli iperparametri * sono variabili in base ai risultati ottenuti di convergenza.

No-quantum ablation obbligatoria. Per ogni regime latente $d \in \{32, 16, 8, 4\}$, tutti i team devono valutare anche una ablation **senza circuito quantistico**, che **coincide con il comparatore classico lineare / logistic regression** sulle feature compresse $u \in \mathbb{R}^d$:

$$\ell(u) = Wu + b, \quad W \in \mathbb{R}^{4 \times d}, b \in \mathbb{R}^4.$$

Questa ablation usa gli stessi split, seed, metriche e protocollo di training del benchmark principale, e serve a verificare se il blocco quantistico aggiunge valore rispetto a una semplice mappa supervisionata sulle feature compresse. MLP e RBF-SVM restano invece comparatori classici aggiuntivi di screening e non coincidono con questa ablation interna.

4 Interfaccia compressione $\rightarrow$ encoding (congelata)

- Regimi latenti comuni obbligatori: $\mathcal{D} = \{32, 16, 8, 4\}$
- Numero qubit: $n_{qubit} \in \{4, 6, 8\}$, dichiarato esplicitamente per ogni configurazione
- Padding: zero-padding se $d \not\equiv 0 \pmod{n_{qubit}}$
- Scaling: min-max su train in $[0, 2\pi]$
- Applicazione scaling: stesso scaler applicato a val/test
- Re-upload schedule: blocchi da n_{qubit} feature per ciclo

Nota. Tutte le trasformazioni devono essere fittate solo su train. Ogni team deve eseguire l'intero sweep su $d \in \mathcal{D}$ prima di aprire variazioni locali su encoding, compressione o ansatz.

Nota aggiuntiva. La no-quantum ablation, coincidente con il comparatore lineare classico sulle feature compresse, prende in input direttamente il vettore compresso $u \in \mathbb{R}^d$, cioè **prima** dello scaling angolare usato per l'encoding quantistico.

Direzione baseline condivisa. In base allo stato dell'arte e alla necessità di mantenere una base confrontabile, la pipeline iniziale usa una soluzione semplice e condivisa: **PCA** come compressione di riferimento, **uno sweep comune sulle dimensioni latenti** $\mathcal{D} = \{32, 16, 8, 4\}$, **angle encoding** con R_Y , features normalizzate in $(0, 2\pi]$, **data re-uploading** quando la dimensione compressa supera il numero di qubit disponibili, e **RealAmplitudes shallow** come ansatz iniziale. Questa scelta è coerente con la pratica documentata in Qiskit e con la letteratura su data re-uploading ed efficienza dei modelli variazionali [15, 10, 11]. La ricerca aggiornata non suggerisce di invertire le priorità tra scelta principale e opzione alternativa: per una pipeline con backbone congelato, embedding compressi e confronto multi-team, l'encoding esplicito con data re-uploading resta la base più pulita, modulare e interpretabile; aggiungere lo sweep su d permette inoltre di misurare in modo esplicito il trade-off tra

compressione e performance senza rompere la confrontabilità di base. Soluzioni più costose o meno modulari, come amplitude encoding o feature map più entanglanti, restano secondarie e non fanno parte della base comune [12, 13, 15].

Scelta suggerita

Come mappare le feature compresse con pochi qubit. Se un ramo usa $d \in \{32, 16, 8, 4\}$ ma ha meno qubit della dimensione latente, la scelta **suggerita** è usare **angle encoding R_Y con data re-uploading esplicito**: si dividono le feature in blocchi, si caricano progressivamente sugli stessi qubit e si alternano blocchi di encoding e blocchi variazionali.

Perché è la scelta migliore qui. È più chiara metodologicamente, è coerente con la letteratura sul data re-uploading, e rende esplicito che gli stessi qubit vengono riusati nel tempo invece di suggerire una falsa corrispondenza tra numero di feature e numero di qubit. Inoltre permette di mantenere **identico l'encoding tra team** e di attribuire le differenze scientifiche soprattutto a compressione e ansatz.

Scelta suggerita

Entangling budget suggerito. Per l'ansatz baseline condiviso, la scelta **suggerita** è un pattern di entanglement **locale e shallow**, preferibilmente **reverse-linear** oppure **linear**, con circa $n_{qubit} - 1$ gate a due qubit per layer entangliante e al massimo due layer entanglianti.

Traduzione pratica per il benchmark. Con $n_{qubit} = 6$, il budget raccomandato è quindi compreso tra **5** e **10** gate a due qubit totali; **12** gate a due qubit può essere accettato come tetto superiore del benchmark, ma non dovrebbe diventare il default.

Perché è la scelta migliore qui. Lo stato dell'arte sui VQC piccoli suggerisce che pattern locali e profondità contenuta offrono il miglior compromesso tra espressività e trainabilità, mentre entanglement troppo ricco o troppo ripetuto aumenta il rischio di circuiti difficili da ottimizzare senza fornire un vantaggio chiaro in un regime a pochi qubit [9, 29, 20].

Opzione alternativa

Opzione alternativa per lo scaling. Oltre al min-max su train in $[0, 2\pi]$, il benchmark può ammettere come confronto secondario uno **scaling robusto train-only a quantili**, seguito da clipping e mappatura in $[\varepsilon, \pi - \varepsilon]$. In pratica, per ogni coordinata compressa si fissano due quantili del train, ad esempio $q_{0.01}$ e $q_{0.99}$, si tronca fuori intervallo e poi si riscalda nel range angolare ristretto.

Quando ha senso. Questa scelta è utile se il min-max standard risulta dominato da outlier oppure se la maggior parte dei campioni finisce compressa in una regione angolare troppo stretta, rendendo l'encoding quasi lineare.

Perché non è il default. Pur essendo spesso più robusta, introduce una scelta aggiuntiva sui quantili e cambia il range angolare rispetto alla base comune. Per questo motivo conviene trattarla come **opzione alternativa esplicitamente etichettata**, non come sostituzione silenziosa della baseline condivisa.

Opzione alternativa

Opzione alternativa. È accettabile anche uno schema in stile benchmark MedMNIST 2026 di Singh, Jin e Merz Jr. [14]: **angle encoding sequenziale lungo** sugli stessi pochi qubit, con molte rotation gates nello strato di encoding e senza formalizzare il tutto come data re-uploading. In quel lavoro compaiono infatti modelli con pochi qubit ma molte feature embeddate tramite molti gate di rotazione nello stesso circuito [14].

Perché resta secondaria. È una scelta praticabile, ma nel nostro caso è meno leggibile come protocollo e rischia di confondere encoding lungo e riuso strutturato delle feature. Per il reduced handout conviene quindi tenerla come **riferimento opzionale**, non come regola principale.

Opzione alternativa

Opzioni alternative per l'entanglement. Oltre al pattern **reverse-linear/linear** suggerito, il benchmark può ammettere come confronto secondario pattern **circular**, **ring**, **ladder** oppure **full**.

Quando hanno senso. Un pattern **circular** o **ring** è ragionevole se si vuole chiudere la catena locale con un solo collegamento aggiuntivo, mantenendo comunque una topologia semplice. Un pattern **ladder** è utile se si vuole simulare una connettività locale leggermente più ricca senza arrivare all'all-to-all. Un pattern **full** è difendibile solo come confronto esplorativo ad alta espressività o come upper bound teorico di connettività.

Perché non sono il default. Queste scelte aumentano il numero totale di gate a due qubit, la profondità circuitale effettiva e il rischio di instabilità di training. In un benchmark centrato su fairness, modularità e piccole dimensioni quantistiche, l'entanglement massimo non è la scelta più pulita. Per questo motivo conviene trattarle come **opzioni alternative esplicitamente etichettate**, non come baseline condivisa.

5 Associazione team-gruppi**Mappatura ufficiale tra team del progetto e identificativi di gruppo****Team A — Gruppo 18**

Ruolo principale: esplorazione dell'encoding quantistico.

Identificativo ufficiale: 18.

Team B — Gruppo 22

Ruolo principale: esplorazione della compressione degli embedding.

Identificativo ufficiale: 22.

Team C — Gruppo 11

Ruolo principale: esplorazione dell'ansatz variazionale.

Identificativo ufficiale: 11.

Regola di coerenza. In tutto il materiale di progetto, i team devono essere identificati con la seguente corrispondenza stabile: **Team A = Gruppo 18**, **Team B = Gruppo 22**, **Team C = Gruppo 11**. La stessa associazione deve comparire in artifact, tabelle, figure, file di configurazione e registri degli esperimenti.

6 Team A**Team A — esplorazione dell'encoding**

Base ereditata. Pipeline condivisa fissata dopo Week 0: risoluzione 224×224 , backbone bloccato, baseline classiche, **PCA** come compressione di riferimento, **sweep comune** su $d \in \{32, 16, 8, 4\}$, encoding R_Y con data re-uploading e **RealAmplitudes shallow** come ansatz iniziale.

Direzione di esplorazione principale. **Encoding quantistico**, mantenendo costanti backbone, compressione baseline, seed e metriche.

Tre casi promettenti.

- **Caso A1 — suggerito:** angle encoding R_Y con **data re-uploading esplicito**. È la scelta più chiara e difendibile per feature compresse più numerose dei qubit disponibili [15, 10, 11].
- **Caso A2:** angle encoding sequenziale lungo sugli stessi qubit, in stile benchmark MedMNIST

2026. È utile come confronto con una pratica sperimentale già usata in letteratura [14].

- **Caso A3:** angle encoding su più assi di rotazione, per esempio R_Y e R_Z a budget di profondità controllato. È una variante promettente quando si vuole aumentare moderatamente la ricchezza spettrale dell'encoding senza passare subito a feature map molto profonde o ricche di gate a due qubit [24, 15].

Vincolo di confronto (obbligatorio).

- Numero qubit fissato: $n_{qubit} = 6$
- Numero totale di rotazioni di encoding: uguale alla dimensione latente del regime considerato, quindi 32, 16, 8 oppure 4
- Numero totale di gate a due qubit: 12
- Numero totale parametri: costante tra i modelli a parità di regime latente

Nota. Le differenze devono derivare solo dallo schema di encoding, non dal budget computazionale; il confronto va quindi mantenuto matched separatamente per ciascun valore di d .

Responsabilità principali.

- Stabilizzare la pipeline comune e verificare che loader, artifact e script modulari siano riusabili da tutti.
- Riprodurre integralmente la baseline condivisa e la no-quantum ablation per tutti i regimi latenti $d \in \{32, 16, 8, 4\}$ prima di aprire i tre casi di encoding.
- Confrontare i tre encoding a parità di compressione, regime latente, seed, comparatore classico e ansatz baseline.
- Introdurre la variazione locale Team A solo dopo il freeze iniziale, così che l'effetto osservato sia attribuibile davvero all'encoding.
- Supportare la rigenerazione coerente degli artifact per few-shot, robustness e packaging finale.

Output attesi. Artifact baseline stabili sull'intero sweep di d , risultati della no-quantum ablation, risultati comparativi A1/A2/A3, predizioni di riferimento e verifica di compatibilità modulare.

Logica di lavoro. Prima consolidare la base comune; poi isolare in modo pulito l'effetto del solo encoding.

7 Team B

Team B — esplorazione della compressione

Base ereditata. Stessa pipeline condivisa di Team A, senza cambiare split, backbone, metriche, risoluzione standard, encoding baseline o ansatz baseline. La compressione di riferimento da cui si parte è **PCA**, valutata nello **sweep comune** su $d \in \{32, 16, 8, 4\}$.

Direzione di esplorazione principale. **Compressione degli embedding** come variazione controllata rispetto alla baseline condivisa.

Tre direzioni di espansione (tutte UNSUPERVISED).

- **Caso B1 — PCA:** baseline lineare.
- **Caso B2 — Autoencoder:** addestrato senza label, loss MSE.
- **Caso B3 — Autoencoder shallow regolarizzato:** variante con vincolo di sparsità o bottleneck più stretto.

Nota critica. Tutti i metodi di compressione devono essere **unsupervised** per isolare l'effetto della compressione. Qualsiasi metodo task-aware sarà trattato come studio separato.

Responsabilità principali.

- Riprodurre integralmente la baseline condivisa e la no-quantum ablation per tutti i regimi latenti $d \in \{32, 16, 8, 4\}$ prima di proporre le tre compressioni.
- Addestrare, congelare e confrontare i tre casi B1/B2/B3 a parità di backbone, regime latente, encoding e ansatz baseline.
- Mantenere invariati encoding, metriche e comparatori quando si isola l'effetto della compressione.
- Usare **VQC** come estensione locale solo dopo aver verificato che la baseline e i tre casi di compressione siano stabili.
- Produrre artifact e script pienamente compatibili con l'architettura modulare comune.

Output attesi. Artifact PCA/AE/AE-regularized sui diversi regimi latenti, risultati della no-quantum ablation, confronti baseline-vs-variation, risultati del ramo Team B e script riusabili nel codice integrato finale.

Logica di lavoro. Prima si replica la base; poi si misura il valore aggiunto della sola compressione.

8 Team C

Team C — esplorazione dell'ansatz

Base ereditata. Stessa pipeline condivisa, stessi artifact congelati, stessi seed, stessa risoluzione standard 224×224 , stessa compressione baseline **PCA**, stesso sweep comune su $d \in \{32, 16, 8, 4\}$ e stesso encoding baseline R_Y con data re-uploading.

Direzione di esplorazione principale. **Ansatz variazionale** come layer di esplorazione sopra la base comune, mantenendo fisso l'encoding baseline.

Tre ansatz promettenti.

- **Caso C1 — RealAmplitudes shallow:** ansatz 2-local con soli strati R_Y ed entanglement leggero. È il riferimento più semplice, trainabile e modulare per partire [9, 20, 29].
- **Caso C2 — EfficientSU2 shallow:** ansatz hardware-efficient più ricco, con rotazioni $SU(2)$ locali e lo stesso budget di profondità controllato. È promettente quando si vuole aumentare espressività senza uscire dal regime 2-local [22, 9, 29].
- **Caso C3 — Topology-aware simulation:** ansatz con pattern di entanglement (ring/ladder) ma **senza riferimento a hardware reale**.

Vincolo di confronto (obbligatorio).

- Pattern baseline suggerito: **reverse-linear** oppure **linear**
- Budget baseline raccomandato: tra $n_{qubit} - 1$ e $2(n_{qubit} - 1)$ gate a due qubit totali
- Con $n_{qubit} = 6$: intervallo raccomandato **5–10** gate a due qubit; **12** ammesso come tetto superiore esplorativo
- Ogni confronto tra ansatz deve essere matched a parità di regime latente e budget entangliante dichiarato

Responsabilità principali.

- Riprodurre la baseline condivisa con encoding R_Y , data re-uploading, sweep comune su d e no-quantum ablation come riferimento comune.
- Valutare in modo controllato i tre casi C1/C2/C3, senza ridefinire la pipeline di base e mantenendo confrontabili i diversi regimi latenti.
- Mantenere separati nei report i risultati **baseline** da quelli **esplorativi** e attribuire le differenze al solo ansatz.

- Gestire robustness, audit finale e test opzionale **28x28** solo come analisi secondaria finale.
- Verificare che i moduli .py prodotti dai gruppi restino componibili in un'unica pipeline eseguibile.

Output attesi. Risultati comparativi C1/C2/C3 sui diversi regimi latenti, risultati della no-quantum ablation, metriche di robustness, audit di compatibilità dei moduli e analisi opzionale 28×28 chiaramente separata dai risultati primari.

Logica di lavoro. Prima si congela il comportamento della base comune; poi si esplora quanto valgono ansatz alternativi mantenendo fisso il resto della pipeline.

9 Timeline compatta

Blocco	Ore progettate	Lavoro principale	Freeze / checkpoint
Week 0	8–12 h / team	Studio dello stato dell'arte, scelta condivisa su preprocessing, risoluzione 224×224 , backbone congelato, PCA baseline, sweep comune su $\mathcal{D} = \{32, 16, 8, 4\}$, comparatore classico lineare / no-quantum ablation, encoding R_Y baseline, RealAmplitudes shallow baseline, e definizione delle interfacce modulari dei file <code>.py</code> .	Freeze della pipeline condivisa iniziale.
Weeks 1–2	18–24 h / team	Setup della pipeline condivisa, test end-to-end, artifact mock e primi run reali sulla base comune, includendo la preparazione dei regimi latenti condivisi e del comparatore lineare comune.	Schema, I/O e modularità fissati; nessun gruppo parte da un ramo indipendente.
Weeks 3–4	18–24 h / team	Screening classico comune e stabilizzazione della baseline condivisa PCA + sweep su d + comparatore lineare / no-quantum ablation + R_Y re-uploading + RealAmplitudes shallow.	baseline comune chiara verificata su tutti i regimi latenti, con controllo lineare completato.
Weeks 5–6	20–28 h / team	Completamento dei run clean sullo sweep comune $d \in \{32, 16, 8, 4\}$, incluso il comparatore lineare / no-quantum ablation, e apertura delle esplorazioni locali: Team A confronta A1/A2/A3 sull'encoding, Team B confronta B1/B2/B3 sulla compressione, Team C confronta C1/C2/C3 sull'ansatz.	Blocco clean principale sui seed 11, 17, 29, con sweep comune e controllo lineare completati.
Week 7	10–14 h / team	Few-shot sui subset condivisi e confronto tra baseline e variazioni.	Freeze del blocco few-shot.
Week 8	12–16 h / team	Robustness, audit finale degli artifact e test opzionale 28x28 solo come analisi secondaria.	Freeze assoluto degli esperimenti; 28×28 non entra come evidenza primaria.
Weeks 9–10	14–20 h / team	Statistiche, figure, scrittura, packaging e fusione coerente dei moduli in una pipeline riusabile.	Nessuna ricomputazione; pacchetto finale integrabile.

10 Regole operative essenziali

Regole operative

- Prima si fissa una **pipeline comune**. Solo dopo lo studio e l'esplorazione della Week 0 si aprono simulazioni locali.
- La base condivisa del benchmark è: **PCA** come compressione di riferimento, **sweep comune** sulle dimensioni latenti $d \in \{32, 16, 8, 4\}$, **angle encoding** R_Y con data re-uploading e **RealAmplitudes shallow** come ansatz iniziale.
- Ogni team deve eseguire integralmente lo **sweep comune** sui regimi latenti prima di aprire variazioni locali su encoding, compressione o ansatz.
- Ogni team deve eseguire anche la **no-quantum ablation**, che **coincide con il comparatore classico lineare / logistic regression** su feature compresse, usando una mappa $\mathbb{R}^d \rightarrow \mathbb{R}^4$ e lo stesso protocollo di training del benchmark principale.
- Le differenze scientifiche intenzionali tra team devono dipendere da variazioni controllate di **encoding**, **compressione** e/o **ansatz**. Non da split, backbone, metriche o comparatori diversi.
- Team A modifica soprattutto l'asse **encoding**, Team B l'asse **compressione**, Team C l'asse **ansatz**, salvo test di integrazione dichiarati esplicitamente e sempre dopo il completamento della pipeline comune su tutti i d .
- Anche il **quantum encoding baseline** deve restare identico tra i team: angle encoding R_Y condiviso, con data re-uploading quando serve.
- Anche il **budget entangliante baseline** deve restare controllato: pattern **reverse-linear/linear** e range raccomandato tra $n_{qubit} - 1$ e $2(n_{qubit} - 1)$ gate a due qubit totali.
- **Selezione comparatore classico**. Il comparatore primario viene selezionato usando SOLO validation set, metrica macro-F1 e media su seed 11, 17, 29. Il modello selezionato viene congelato dopo Week 4 e non può essere cambiato.
- La risoluzione standard della pipeline è **224x224**. Il test **28x28** è solo opzionale e finale.
- La compressione si fitta solo su **train**. Val e test si trasformano con l'oggetto già congelato.
- Il few-shot cambia solo il training set. Val e test non si ridefiniscono.
- I moduli `.py` devono essere separabili e componibili: preprocessing, embedding, compressione, encoding, ansatz, training, evaluation e reporting devono poter essere fusi in un'unica pipeline.
- Ogni risultato deve essere etichettato chiaramente come **baseline condivisa** oppure **variazione esplorativa**.
- La robustezza non si misura da predizioni clean già salvate: si ricomputa l'intera pipeline sulle immagini corrotte.
- Dopo la settimana 8 non si aggiungono nuovi esperimenti. Un risultato mancante si esclude, non si recupera tardi.
- Se un file non è tracciato, validato e rigenerabile da script, non entra nel paper.

11 Rischi principali e prevenzione

- **Troppi gradi di libertà prima del freeze iniziale.** Si evita imponendo una Week 0 obbligatoria e una pipeline condivisa fissata prima di qualunque esplorazione locale.
- **Sweep latente incompleto o asimmetrico tra team.** Si evita imponendo che tutti i gruppi eseguano gli stessi run comuni per $d \in \{32, 16, 8, 4\}$ prima delle variazioni locali.
- **Assenza di controllo sul contributo quantistico.** Si evita imponendo un **comparatore lineare obbligatorio**, coincidente con la **no-quantum ablation** sulle feature compresse, così è possibile capire se il blocco quantistico aggiunge davvero valore oltre a una semplice testa supervisionata.
- **Confusione tra baseline ed esplorazione.** Si evita marcando sempre nei file e nelle tabelle che cosa appartiene alla base comune e che cosa è variazione del gruppo.
- **Confusione tra gruppi A/B/C.** Si evita imponendo che Team A esplori l'encoding, Team B la compressione e Team C l'ansatz, ma solo dopo che tutti hanno completato il benchmark comune sugli stessi regimi latenti.
- **Confronto unfair.** Si evita mantenendo uguali split, seed, metriche, backbone, risoluzione standard 224×224 , budget di screening e comparatore primario.
- **Leakage nella compressione.** Si evita fitando sempre solo su train e congelando subito il compressore.
- **Mancanza di modularità del codice.** Si evita progettando fin dalla Week 0 interfacce .py pulite, naming coerente e contratti I/O stabili.
- **Impossibilità di fondere gli script finali.** Si evita separando preprocessing, embedding, compressione, encoding, ansatz, training, evaluation e reporting in moduli riusabili.
- **Instabilità dei VQC.** Si evita fissando un criterio minimo chiaro: una cella reale stabile a $d = 16$ entro la settimana 5.
- **Uso improprio del test 28×28 .** Si evita trattandolo solo come analisi finale opzionale e non come evidenza primaria del benchmark.
- **Caos negli artifact.** Si evita con schema unico, naming coerente, versionamento e checklist di validazione settimanale.

12 Checklist finale per gli studenti

Ogni team, prima di dichiarare una settimana completata, deve poter rispondere **sì** a tutte queste domande:

1. Ho eseguito integralmente lo **sweep comune** sulle dimensioni latenti $d \in \{32, 16, 8, 4\}$ previsto dal benchmark principale?
2. Ho eseguito il **comparatore classico lineare**, coincidente con la **no-quantum ablation**, per ciascun regime latente previsto?
3. Sto aderendo alla **pipeline condivisa fissata** dopo la Week 0, cioè **PCA + R_Y con data re-uploading + RealAmplitudes shallow** come base?
4. Ho mantenuto la risoluzione standard **224x224** per i risultati principali e trattato **28x28** solo come test finale opzionale?
5. Ho tracciato chiaramente che cosa è **baseline comune** e che cosa è **variazione locale**?
6. Sto esplorando soprattutto l'asse assegnato al mio team, senza mischiare encoding, compressione e ansatz in modo da rendere il confronto opaco?
7. Ho prodotto artifact compatibili con i contratti comuni e con i moduli degli altri gruppi?

8. I miei script `.py` sono abbastanza modulari da poter essere fusi in un'unica pipeline eseguibile?
9. I miei CSV e JSON rispettano lo schema comune?
10. Posso ricostruire il risultato da script senza passaggi manuali o notebook locali?
11. Se confronto il mio ramo con gli altri, le differenze rimaste sono davvero interpretabili come effetto di una variazione controllata di encoding, compressione e/o ansatz?

Regola pratica finale. Pensate sempre così: *groundwork comune* $\rightarrow$ *pipeline condivisa fissata* $\rightarrow$ *sweep comune su d* $\rightarrow$ *comparatore lineare / no-quantum ablation* $\rightarrow$ *variazione locale controllata* $\rightarrow$ *output tracciati*. Se il vostro lavoro salta il freeze iniziale, non completa i regimi latenti condivisi, non esegue questo controllo lineare obbligatorio o produce script non integrabili, la struttura operativa non sta venendo rispettata.

Materiale supplementare

Questa pagina raccoglie i riferimenti più utili per chi deve implementare rapidamente la pipeline e capire dove si collocano le scelte tecniche del progetto.

- **Dataset e benchmark:** per capire struttura, split e rationale di *OCTMNIST*, partire da MedMNIST v2 [1]. Per l'uso pratico del dataset, delle split ufficiali e delle varianti di risoluzione, usare anche il sito/repo ufficiale MedMNIST [2].
- **Nota operativa sulla risoluzione:** il paper MedMNIST v2 formalizza il benchmark leggero a **28x28**; il sito ufficiale e il repository rilasciano anche **MedMNIST+** con taglie **64/128/224**. Nel nostro progetto, quindi, la pipeline principale a **224x224** va intesa come uso esplicito della variante large-size, mentre **28x28** resta un confronto secondario finale e non la base primaria [1, 2].
- **Backbone e preprocessing:** per il ruolo di *ResNet-18* come estrattore di embedding, il riferimento standard è [3]. In implementazione conviene fissare anche il contratto di preprocessing di TorchVision: usare i pesi ufficiali di **resnet18**, le relative transform standard e feature estratte **dopo avgpool e prima di fc**, così l'embedding condiviso resta davvero stabile in $\mathbb{R}^{512}$ [4, 5].
- **Compressione:** per *PCA* e riduzione lineare usare [6]; per l'idea di compressione tramite autoencoder il riferimento classico è [7].
- **VQC e pipeline ibride:** per inquadrare circuiti quantistici parametrizzati e algoritmi variazionali sono particolarmente utili [8, 9].
- **Encoding quantistico suggerito:** lo stato dell'arte pratico per VQC piccoli favorisce encoding semplici e condivisi. Per questo handout la sintesi operativa consigliata è: R_Y angle encoding, features riscalate in $(0, 2\pi]$, e data re-uploading quando $d > n_{\text{qubit}}$ [15, 10, 11, 12, 13].
- **Stack quantistico consigliato:** per una implementazione aderente a questo handout, la scelta più pulita è usare **StatevectorEstimator** come backend di default, **EstimatorQNN** per produrre expectation values e **TorchConnector** per collegare il blocco quantistico alla testa lineare classica in PyTorch [17, 18, 19]. Questo è più coerente con il contratto “expectation values + linear head” rispetto a una convenience class più astratta.
- **Documentazione Qiskit utile:** per chi implementa un VQC in pratica, la documentazione introduttiva di Qiskit [16], la guida sul data encoding [15], e la documentazione delle famiglie **real_amplitudes** [21] e **efficient_su2** [23] sono ottime basi per capire come costruire ansatz compatti, scegliere il pattern di entanglement e controllare il parametro **reps**. Le classi legacy **RealAmplitudes** e **EfficientSU2** restano utili come riferimento concettuale, ma nelle versioni recenti di Qiskit conviene preferire le omologhe funzioni [20, 22].
- **Metriche operative da congelare:** per evitare confronti non allineati, conviene fissare in modo esplicito che **Macro-AUROC** sia calcolata in multiclass **one-vs-rest** sulle probabilità di classe, che **Macro-F1** e **balanced accuracy** siano calcolate sulle label ottenute via arg max, e che **ECE** sia la **top-label multiclass calibration error** con **15 bin uniformi** e **norma L1** [25, 26, 27, 28].
- **Artifact minimi consigliati:** oltre alle metriche aggregate, conviene salvare sempre **y_true**, **logits**, **probabilities**, **y_pred**, **seed**, valore di **d**, numero di qubit, schema di encoding, ansatz, versione delle librerie e identificativo del run. Questo rende audit, error analysis ed eventuale fusione finale dei moduli molto più semplici.
- **Versioni software:** per massimizzare la riproducibilità, ogni gruppo dovrebbe registrare almeno le versioni di **python**, **torch**, **torchvision**, **qiskit**, **qiskit-machine-learning**, **scikit-learn** e **torchmetrics**. Nei benchmark modulari piccoli, molte differenze apparentemente “scientifiche” derivano in realtà da differenze di ambiente.
- **Instabilità del training quantistico:** per capire perché aumentare troppo qubit e profondità può rendere difficile l'ottimizzazione, leggere [29].

Riferimenti bibliografici

- [1] Jiancheng Yang, Rui Shi, Donglai Wei, Zequan Liu, Lin Zhao, Bilian Ke, Hanspeter Pfister, e Bingbing Ni. MedMNIST v2: A large-scale lightweight benchmark for 2D and 3D biomedical image classification. *Scientific Data*, 10:41, 2023. doi: [10.1038/s41597-022-01721-8](https://doi.org/10.1038/s41597-022-01721-8).
- [2] MedMNIST authors and maintainers. MedMNIST official website and repository, including MedMNIST+ multiple-size releases. Accessed 2026. <https://medmnist.com/>.
- [3] Kaiming He, Xiangyu Zhang, Shaoqing Ren, e Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016. doi: [10.1109/CVPR.2016.90](https://doi.org/10.1109/CVPR.2016.90).
- [4] TorchVision documentation team. `torchvision.models.resnet18` documentation and official pretrained transforms. Accessed 2026. <https://docs.pytorch.org/vision/main/models/generated/torchvision.models.resnet18.html>.
- [5] TorchVision documentation team. Feature extraction utilities and `create_feature_extractor`. Accessed 2026. https://docs.pytorch.org/vision/0.17/feature_extraction.html.
- [6] Harold Hotelling. Analysis of a complex of statistical variables into principal components. *Journal of Educational Psychology*, 24(6):417–441, 1933. doi: [10.1037/h0071325](https://doi.org/10.1037/h0071325).
- [7] Geoffrey E. Hinton e Ruslan R. Salakhutdinov. Reducing the dimensionality of data with neural networks. *Science*, 313(5786):504–507, 2006. doi: [10.1126/science.1127647](https://doi.org/10.1126/science.1127647).
- [8] Marcello Benedetti, Erika Lloyd, Stefan Sack, e Mattia Fiorentini. Parameterized quantum circuits as machine learning models. *Quantum Science and Technology*, 4(4):043001, 2019. doi: [10.1088/2058-9565/ab4eb5](https://doi.org/10.1088/2058-9565/ab4eb5).
- [9] M. Cerezo, Andrew Arrasmith, Ryan Babbush, et al. Variational quantum algorithms. *Nature Reviews Physics*, 3:625–644, 2021. doi: [10.1038/s42254-021-00348-9](https://doi.org/10.1038/s42254-021-00348-9).
- [10] Adrián Pérez-Salinas, Alba Cervera-Liarta, Elies Gil-Fuster, e José I. Latorre. Data re-uploading for a universal quantum classifier. *Quantum*, 4:226, 2020. doi: [10.22331/q-2020-02-06-226](https://doi.org/10.22331/q-2020-02-06-226).
- [11] Sofiene Jerbi, Lukas J. Fiderer, Hendrik Poulsen Nautrup, Jonas M. Kübler, Hans J. Briegel, e Vedran Dunjko. Quantum machine learning beyond kernel methods. *Nature Communications*, 14:517, 2023. doi: [10.1038/s41467-023-36159-y](https://doi.org/10.1038/s41467-023-36159-y).
- [12] Xiao-Ming Zhang e Xiao Yuan. Circuit complexity of quantum access models for encoding classical data. *npj Quantum Information*, 10:42, 2024. doi: [10.1038/s41534-024-00835-8](https://doi.org/10.1038/s41534-024-00835-8).
- [13] Riddhi S. Gupta, Carolyn E. Wood, Teyl Engstrom, Jason D. Pole, e Sally Shrapnel. A systematic review of quantum machine learning for digital health. *npj Digital Medicine*, 8:237, 2025. doi: [10.1038/s41746-025-01597-z](https://doi.org/10.1038/s41746-025-01597-z).
- [14] Gurinder Singh, Hongni Jin, e Kenneth M. Merz Jr. Benchmarking MedMNIST dataset on real quantum hardware. *Scientific Reports*, 16:9017, 2026. doi: [10.1038/s41598-026-35605-3](https://doi.org/10.1038/s41598-026-35605-3).
- [15] IBM Quantum documentation team. Data encoding. IBM Quantum Learning, accessed 2026. <https://qiskit.qotlabs.org/learning/courses/quantum-machine-learning/data-encoding>.
- [16] Qiskit documentation team. Qiskit documentation and introductory materials. <https://qiskit.org/documentation/>.
- [17] IBM Quantum documentation team. Exact simulation with Qiskit SDK primitives and `StatevectorEstimator`. Accessed 2026. <https://qiskit.qotlabs.org/docs/guides/simulate-with-qiskit-sdk-primitives>.

- [18] Qiskit Machine Learning documentation team. **EstimatorQNN** documentation. Accessed 2026. https://qiskit-community.github.io/qiskit-machine-learning/stubs/qiskit_machine_learning.neural_networks.EstimatorQNN.html.
- [19] Qiskit Machine Learning documentation team. **Torch Connector and Hybrid QNNs**. Accessed 2026. https://qiskit-community.github.io/qiskit-machine-learning/tutorials/05_torch_connector.html.
- [20] Qiskit documentation team. **RealAmplitudes** circuit documentation. <https://qiskit.qotlabs.org/docs/api/qiskit/qiskit.circuit.library.RealAmplitudes>.
- [21] IBM Quantum documentation team. **real_amplitudes** function documentation. Accessed 2026. https://qiskit.qotlabs.org/docs/api/qiskit/qiskit.circuit.library.real_amplitudes.
- [22] Qiskit documentation team. **EfficientSU2** circuit documentation. <https://qiskit.qotlabs.org/docs/api/qiskit/qiskit.circuit.library.EfficientSU2>.
- [23] IBM Quantum documentation team. **efficient_su2** function documentation. Accessed 2026. https://qiskit.qotlabs.org/docs/api/qiskit/qiskit.circuit.library.efficient_su2.
- [24] Maria Schuld, Ryan Sweke, e Johannes Jakob Meyer. Effect of data encoding on the expressive power of variational quantum-machine-learning models. *Physical Review A*, 103(3):032430, 2021. doi: [10.1103/PhysRevA.103.032430](https://doi.org/10.1103/PhysRevA.103.032430).
- [25] scikit-learn documentation team. **roc_auc_score** documentation. Accessed 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_auc_score.html.
- [26] scikit-learn documentation team. **f1_score** documentation. Accessed 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html.
- [27] scikit-learn documentation team. **balanced_accuracy_score** documentation. Accessed 2026. https://scikit-learn.org/1.2/modules/generated/sklearn.metrics.balanced_accuracy_score.html.
- [28] TorchMetrics documentation team. **Calibration Error** documentation. Accessed 2026. https://lightning.ai/docs/torchmetrics/stable/classification/calibration_error.html.
- [29] Jarrod R. McClean, Sergio Boixo, Vadim N. Smelyanskiy, Ryan Babbush, e Hartmut Neven. Barren plateaus in quantum neural network training landscapes. *Nature Communications*, 9:4812, 2018. doi: [10.1038/s41467-018-07090-4](https://doi.org/10.1038/s41467-018-07090-4).

13 Idee di ricerca attraenti per la pipeline

13.1 Readout quantistico arricchito con correlazioni come upgrade minimo ma ad alto valore

Tra le possibili estensioni della pipeline, una delle più interessanti è mantenere invariati input compresso, famiglia di encoding e circuito variazionale, ma sostituire il readout puramente locale

$$\mathcal{O}_{\text{base}} = \{Z_1, \dots, Z_n\}$$

con una famiglia di osservabili leggermente arricchita

$$\mathcal{O}_E = \{Z_i\}_{i=1}^n \cup \{Z_i Z_j\}_{(i,j) \in E},$$

dove E è un piccolo insieme di archi fissato **prima** degli esperimenti. Il corrispondente vettore di feature quantistiche diventa

$$m_E(x) = \left(\langle Z_i \rangle, \langle Z_i Z_j \rangle_{(i,j) \in E} \right) \in \mathbb{R}^p, \quad p = n + |E|,$$

e il classificatore agisce tramite

$$\ell(x) = W_E m_E(x) + b, \quad W_E \in \mathbb{R}^{4 \times p}.$$

L'idea è piccola sul piano implementativo ma importante sul piano teorico: la baseline osserva solo margini a un corpo e può quindi non distinguere stati che differiscono solo nelle correlazioni a coppie. Con il readout arricchito cambia lo spazio osservabile su cui si basa il classificatore, senza dover riscrivere il resto della pipeline.

13.2 Perché l'idea è interessante

Il vantaggio principale è che questo upgrade rilassa il collo di bottiglia osservabile senza far esplodere complessità o costi di implementazione. A differenza di un readout con X_i e Y_i , gli osservabili Z_i e $Z_i Z_j$ commutano, quindi in una versione shot-based possono essere stimati dagli stessi bitstring in base computazionale.

Dal punto di vista scientifico, la proposta ha quattro vantaggi principali:

1. rende più informativi i confronti tra ansatz, perché differenze di entanglement possono emergere al livello del readout;
2. preserva l'architettura di base del benchmark, lasciando invariati compressione, encoding, split e politica few-shot;
3. resta modulare, perché modifica solo il readout e la testa lineare;
4. permette di studiare se correlazioni quantistiche a coppie aggiungono valore oltre ai soli riassunti locali.

13.3 Impatto sulla pipeline

L'effetto principale è che la classe di modelli passa da decisioni lineari nello spazio delle sole expectation locali a decisioni lineari in uno spazio misto one-body/two-body. Questo può rendere più leggibili:

- il contributo di ansatz più ricchi, che sotto solo readout locale possono apparire artificialmente simili;
- le differenze tra encoding, se questi inducono profili di correlazione diversi a parità di margini locali;
- il ruolo della compressione, che verrebbe valutata anche per la capacità di preservare relazioni utili al circuito.

Il punto critico è la fairness: la dimensione della testa cresce da n a $p = n + |E|$, quindi una parte del guadagno potrebbe derivare dall'aumento di capacità del classificatore lineare. Per questo motivo serve un controllo classico matched.

13.4 Scelta dell'insieme di archi e controllo classico matched

L'insieme E deve essere fissato prima degli esperimenti. Le scelte più naturali sono una catena, un anello, oppure la scelta più forte teoricamente: usare esattamente gli archi di entanglement dell'ansatz baseline,

$$E = E_{\text{ansatz}}.$$

Questa scelta rende il readout più interpretabile e riduce arbitrarietà.

Per mantenere il confronto difendibile, bisogna aggiungere anche un controllo classico matched sul latente compresso:

$$\phi_E(u) = \left(u_i, u_i u_{j(i,j) \in E} \right) \in \mathbb{R}^p,$$

seguito da una testa lineare

$$\ell_{\text{class}}(u) = \widetilde{W} \phi_E(u) + \widetilde{b}, \quad \widetilde{W} \in \mathbb{R}^{4 \times p}.$$

Questo controllo è importante perché:

1. pareggia la dimensione della testa;
2. introduce struttura del secondo ordine anche sul lato classico;
3. rende più chiara la domanda scientifica: il guadagno dipende da correlazioni quantistiche osservate oppure dall'aggiunta di feature quadratiche?

13.5 Strategia consigliata e rischi

La soluzione più pulita non è sostituire subito la baseline, ma preregistrare due protocolli:

Protocollo 1: $\mathcal{O}_{\text{base}} = \{Z_i\},$

Protocollo 2: $\mathcal{O}_E = \{Z_i\} \cup \{Z_i Z_j\}_{(i,j) \in E}.$

Sul lato classico il confronto naturale diventa:

Controllo classico 1: $u \mapsto Wu + b,$

Controllo classico 2: $u \mapsto \widetilde{W} \phi_E(u) + \widetilde{b}.$

In questo modo si ottiene un confronto a quattro vie: baseline quantistica vs baseline classica, readout arricchito vs controllo quadratico, upgrade quantistico a parità di circuito, upgrade classico a parità di input compresso.

I rischi principali restano chiari:

- la testa classica cresce e può assorbire parte del miglioramento;
- i correlatori diagonali $Z_i Z_j$ non catturano comunque tutta la struttura di fase;
- se $|E|$ cresce troppo, il benchmark perde minimalità;
- se E viene scelto post hoc, il confronto perde rigore.

13.6 Raccomandazione finale

La raccomandazione più solida è:

1. mantenere il readout locale $\{Z_i\}$ come baseline canonica;
2. aggiungere $\{Z_i\} \cup \{Z_i Z_j\}_{(i,j) \in E}$ come estensione preregistrata;
3. usare il controllo classico sparso-quadratico matched $\phi_E(u)$;

4. scegliere E in accordo con il grafo di entanglement baseline;
5. riportare non solo le performance assolute, ma anche il guadagno incrementale rispetto sia alla baseline quantistica sia a quella classica.

Se eseguito con questa disciplina, l'upgrade rende il benchmark più rigoroso sul piano causale e più informativo nel collegare readout, ansatz e controlli classici matched.