

Benchmark Quantum–Classical su Embedding OCT Compresi:

Esplorazione della Compressione degli Embedding (Team B)

Gruppo 22 — Progetto FVAB

Abstract

Questo lavoro presenta il contributo del Team B all'interno di un progetto multi-team per la classificazione di immagini OCT (dataset OCTMNIST, 4 classi) mediante una pipeline ibrida classico-quantistica. Il mandato del Team B è l'esplorazione della compressione degli embedding: a partire da un backbone ResNet-18 congelato (pesi pre-addestrati su MedMNIST) che produce feature a 512 dimensioni, vengono confrontati tre metodi di riduzione dimensionale — PCA (B1), un autoencoder vanilla (B2) e un autoencoder shallow con penalità di sparsità (B3) — a parità di encoding quantistico, ansatz variazionale, metriche e protocollo sperimentale, come richiesto dalla baseline condivisa e congelata del progetto. Il confronto avviene su due livelli: (i) un'ablation obbligatoria *no-quantum*, in cui un classificatore lineare (Logistic Regression) viene addestrato direttamente sulle feature compresse, e (ii) la pipeline quantistica completa, in cui un circuito variazionale (VQC) con data re-uploading multi-ciclo classifica le stesse feature. I risultati dell'ablation classica mostrano che i tre compressor producono rappresentazioni quasi equivalenti a dimensione latente piena o intermedia ($d = 32, 16$: macro-F1 nell'intervallo 0,85–0,87), ma divergono nettamente a dimensioni ridotte: a $d = 4$ il compressore regolarizzato (B3) crolla a macro-F1 0,74 contro 0,86 di PCA (B1), un divario assente alle dimensioni più alte. Emerge inoltre un trade-off di calibrazione: B3 ottiene un Expected Calibration Error sistematicamente inferiore agli altri due compressor su ogni dimensione, nonostante la perdita di potere discriminativo a d bassa.

La pipeline quantistica completa, con circuito a data re-uploading e ottimizzatore NFT, ottiene una macro-F1 di test media di 0,484 (deviazione standard 0,171) sulle 36 combinazioni testate, contro $\sim 0,86$ della Logistic Regression: un divario sostanziale ma un comportamento nel complesso stabile, non collassato. Emerge inoltre un pattern di interazione compressore–dimensione opposto tra B1 e B2, B3: B1 favorisce dimensioni latenti basse (macro-F1 0,73 a $d = 4$), mentre B2 e B3 favoriscono dimensioni alte (macro-F1 $\sim 0,66$ –0,69 a $d = 32$). Va precisato che questo non riflette una differenza di informazione disponibile — per costruzione della PCA, $d = 32$ contiene sempre almeno tutta l'informazione di $d = 4$, confermato empiricamente dalla Logistic Regression, dove $d = 32$ è leggermente migliore di $d = 4$ — ma di quanta di questa informazione il circuito VQC riesce a estrarre con il budget di ottimizzazione disponibile, che

si riduce all'aumentare della profondità richiesta dal re-uploading. Un confronto diretto con un MLP addestrato nello stesso regime few-shot del VQC (32 campioni) rivela un'inversione sorprendente: l'MLP supera nettamente il VQC su B1 e B2, ma il VQC supera l'MLP su B3 su ogni dimensione, verosimilmente perché il ricampionamento del batch ad ogni epoca — assente nell'addestramento dell'MLP few-shot, presente in quello del VQC — agisce da regolarizzazione implicita cruciale sulle feature sparse e vincolate in $[0, 1]$ prodotte da B3.

1 Introduzione e Descrizione del Problema

La classificazione di immagini biomediche mediante circuiti quantistici variazionali (VQC) è un'area di ricerca emergente che si interroga su quando e come un blocco quantistico possa aggiungere valore rispetto a pipeline puramente classiche. Il progetto FVAB affronta questa domanda nel contesto specifico della classificazione di immagini OCT della retina (OCTMNIST, 4 classi), adottando un disegno sperimentale a tre team paralleli che condividono un'infrastruttura comune e congelata, esplorando ciascuno un asse diverso della pipeline: il Team A esplora varianti di encoding quantistico, il Team C esplora ansatz variazionali alternativi, e il Team B — oggetto di questo lavoro — esplora strategie di compressione degli embedding.

Il vincolo tecnico che definisce il problema è la disponibilità limitata di qubit simulabili (4, per ragioni di trattabilità su hardware classico con memoria limitata) a fronte di embedding compressi di dimensione fino a 32. Poiché il numero di feature può eccedere il numero di qubit disponibili, la pipeline condivisa adotta uno schema di *data re-uploading*: le feature compresse vengono suddivise in blocchi di dimensione pari al numero di qubit e caricate progressivamente sugli stessi qubit, alternando blocchi di encoding angolare (R_y) e blocchi variazionali (RealAmplitudes shallow).

In questo contesto, il Team B affronta tre domande di ricerca specifiche:

1. La scelta del metodo di compressione (lineare, PCA, contro non lineare, autoencoder) influenza il potere discriminativo delle feature risultanti, a parità di classificatore a valle?
2. Esiste un'interazione tra la struttura interna delle feature compresse (ordinate per varianza, come in PCA, oppure non ordinate, come in un autoencoder) e l'allenabilità del circuito quantistico con re-

uploading, la cui profondità cresce con il numero di blocchi necessari a coprire l'intera dimensione compressa?

3. Esiste un trade-off tra potere discriminativo grezzo (F1, AUROC) e calibrazione delle probabilità (ECE) tra i tre metodi di compressione, rilevante in un dominio clinico dove la fiducia associata a una predizione ha un peso specifico?

Il resto del lavoro è organizzato come segue: la Sezione 3 inquadra il lavoro rispetto allo stato dell'arte su compressione, encoding quantistico e ottimizzazione di VQC; la Sezione 4 descrive l'architettura proposta e le scelte implementative; la Sezione 5 presenta i risultati sperimentali; la Sezione 6 li discute criticamente, incluse le difficoltà di ottimizzazione incontrate; la Sezione 7 conclude con limitazioni e lavoro futuro.

2 Stato dell'Arte / Related Works

2.1 Compressione di embedding

La Principal Component Analysis (PCA) [4] resta il metodo di riferimento per la riduzione dimensionale lineare non supervisionata, con la proprietà di ordinare le componenti per varianza spiegata decrescente. Gli autoencoder [5] rappresentano l'estensione non lineare di questo paradigma: un autoencoder vanilla apprende una rappresentazione compressa minimizzando l'errore di ricostruzione (MSE), senza alcun vincolo esplicito sulla struttura dello spazio latente; varianti regolarizzate — ad esempio con penalità di sparsità L_1 sulle attivazioni latenti — inducono rappresentazioni più sparse e potenzialmente più robuste, a costo di una minore capacità di ricostruzione.

2.2 Encoding quantistico e data re-uploading

Con un numero di qubit inferiore alla dimensione delle feature classiche da codificare, lo schema di data re-uploading [1] permette di iniettare più volte le stesse risorse quantistiche con blocchi di dati diversi, alternando rotazioni di encoding e strati variazionali trainabili. Il risultato teorico che ne motiva l'adozione [8] è che un singolo qubit ri-caricato ripetutamente con un ansatz trainabile tra un caricamento e l'altro può approssimare funzioni arbitrariamente complesse, rendendo l'approccio una scelta consolidata quando il numero di feature eccede il numero di qubit disponibili.

2.3 Ansatz variazionali e ottimizzazione

I circuiti quantistici variazionali parametrizzati [6, 7] costituiscono il paradigma alla base del VQC impiegato in questo lavoro. RealAmplitudes è un ansatz 2-local hardware-efficient, composto da soli strati di rotazione R_y ed entanglement lineare, ampiamente documentato come baseline shallow per VQC di piccole dimensioni. Per l'ottimizzazione dei parametri variazionali, accanto ai metodi basati su gradiente (Adam, SPSSA) esistono ottimizzatori gradient-free specifici per circuiti parametrizzati con struttura sinusoidale nota, come Nakanishi-Fujii-Todo (NFT), che sfruttano la forma analitica della funzione di costo rispetto a cias-

cun parametro per trovarne il minimo con poche valutazioni, senza stimare gradienti.

2.4 Posizionamento del presente lavoro

Un lavoro direttamente comparabile è quello di Singh, Jin e Merz [10], che valuta VQC su benchmark MedMNIST direttamente su hardware quantistico reale; il presente lavoro se ne distingue per il focus specifico sulla compressione a monte, mantenuta come unico asse di variazione. L'applicabilità clinica di pipeline QML resta inoltre un'area di ricerca attiva [9], a cui il trade-off di calibrazione discusso in Sezione 5.2 contribuisce direttamente. Rispetto a questa letteratura, il contributo specifico del Team B è empirico: isolare l'effetto della sola strategia di compressione a parità di tutto il resto della pipeline (encoding, ansatz, ottimizzatore, protocollo di split e metriche), e documentare in modo trasparente le difficoltà di ottimizzazione incontrate nell'applicare un ansatz re-uploading multi-ciclo con un ottimizzatore gradient-free, un aspetto raramente discusso in dettaglio nella letteratura applicativa.

3 Sistema Proposto

3.1 Pipeline complessiva

La pipeline segue lo schema condiviso e congelato del progetto:

Immagine OCT (224×224) → ResNet-18 congelato (pesi MedMNIST) → embedding 512-dim → Compressore (B1/B2/B3) → vettore d-dim → VQC (data re-uploading) → classificatore lineare → 4 logit

Il backbone ResNet-18 [3] è condiviso e identico per tutti i team: le feature vengono estratte dopo il global average pooling e prima del layer fully-connected finale, con pesi mai aggiornati durante l'addestramento a valle.

3.2 I tre compressor confrontati

- **B1 — PCA:** riduzione lineare, fittata esclusivamente sul training set per ciascuna dimensione latente $d \in \{32, 16, 8, 4\}$ e ciascun seed; val e test sono trasformati con l'oggetto fittato, senza refit.
- **B2 — Autoencoder vanilla:** architettura $512 \rightarrow 128 \rightarrow d \rightarrow 128 \rightarrow 512$, funzione di perdita MSE, addestramento non supervisionato.
- **B3 — Autoencoder shallow regolarizzato:** architettura $512 \rightarrow d$ (sigmoide) $\rightarrow 512$, funzione di perdita $MSE + \lambda \|z\|_1$ ($\lambda = 10^{-3}$).

Tutti e tre i compressor condividono lo stesso protocollo di fit (solo train, mai su val/test), le stesse dimensioni latenti $D = \{32, 16, 8, 4\}$ e gli stessi tre seed di controllo (11, 17, 29).

3.3 Protocollo dati e split

Il test set è fisso e condiviso da tutti i seed, costruito unendo lo split di validation e lo split di test canonici di MedMNIST (~ 11.832 immagini) — un insieme mai

osservato dal backbone ResNet-18 durante il proprio pre-training. Il seed controlla esclusivamente la suddivisione train/validation all'interno del pool di training canonico. Questo disaccoppiamento elimina sia la varianza spuria tra seed dovuta a un test set diverso ad ogni run, sia il rischio di data leakage dal backbone.

3.4 Circuito quantistico: encoding congelato con data re-uploading

Il numero di qubit è fissato a 4 (pari al numero di classi). Per ciascuna dimensione latente d , il numero di cicli di re-uploading è $n_{\text{cicli}} = \lceil d/4 \rceil$, con zero-padding se d non è multiplo di 4 (mai necessario per $D = \{32, 16, 8, 4\}$). Ogni ciclo codifica un nuovo blocco di 4 feature tramite rotazioni R_y , seguito da un blocco variazionale RealAmplitudes [12] (reps = 2, entanglement lineare). I pesi variazionali sono indipendenti per ciclo: una variante a pesi condivisi tra cicli è stata esplorata e scartata (Sezione 5.3) in quanto empiricamente meno performante. Le feature sono scalate con un min-max scaler fissato esclusivamente sul training set (range $[0, 2\pi]$, scelta discussa in Sezione 5.4) e applicato identicamente a validation e test.

Il documento di progetto raccomanda un budget di entangling tra $n_{\text{qubit}} - 1$ e $2(n_{\text{qubit}} - 1)$ gate a due qubit *totali* (3–6 per $n_{\text{qubit}} = 4$). Con pesi indipendenti per ciclo, il circuito qui descritto usa 6 gate a due qubit per ciclo (reps = 2, entanglement lineare su 4 qubit), per un totale di $6 \times n_{\text{cicli}}$ — entro il range raccomandato solo per $d = 4$ ($n_{\text{cicli}} = 1$), e fino a $8 \times$ oltre per $d = 32$ ($n_{\text{cicli}} = 8$). Un budget totale fisso indipendente da d è, tuttavia, in tensione strutturale con il re-uploading multi-ciclo obbligatorio per $d > n_{\text{qubit}}$: due blocchi di encoding R_y consecutivi senza un blocco entangling intermedio si sommerebbero in un'unica rotazione (le rotazioni attorno allo stesso asse commutano), riducendo il re-uploading a una somma di rotazioni prive delle trasformazioni non lineari intermedie che ne motivano l'adozione [1]. Si è quindi interpretato il budget come riferito al singolo blocco ansatz per ciclo — l'unica lettura che preserva un re-uploading funzionante per ogni $d \in D$ — pur riconoscendo che il documento non specifica esplicitamente questa granularità.

3.5 Ottimizzazione: NFT al posto di Adam

Il protocollo di training condiviso indica Adam (lr = 0,001) come ottimizzatore di riferimento, marcando però esplicitamente alcuni iperparametri come variabili in base ai risultati di convergenza osservati. In fase preliminare, l'ottimizzazione basata su gradiente (Adam e SPSA) attraverso il simulatore statevector si è dimostrata instabile, con collasso della loss vicino al valore di un classificatore casuale ($\ln 4 \approx 1,386$) e accuracy media attorno al 55%. È stato quindi adottato Nakanishi-Fujii-Todo (NFT), che sfrutta la struttura sinusoidale esatta dei gate di rotazione per trovare il minimo analitico di ciascun parametro con poche valutazioni. Il budget di valutazioni NFT è scalato in funzione del numero di parametri trainabili (floor di

300 valutazioni, ≈ 3 sweep completi per parametro), per non penalizzare le configurazioni con più cicli di re-uploading.

Per completezza documentale, la configurazione Adam (lr = 0,001) di default è stata comunque eseguita fino in fondo, in modo indipendente dalla pipeline principale, su un'architettura più semplice priva di re-uploading (**StabilizedVQC**, backpropagation diretta sul simulatore, script `week4_sweep_production.py`). Su tutte le 12 combinazioni ($d \times \text{seed}$), l'accuracy di validazione media è 29,83% (deviazione standard 10,41%, range 12,5–44,0%) — praticamente al livello del caso casuale per un problema a 4 classi (25%), con 3 combinazioni su 12 addirittura al di sotto. Questo risultato, ottenuto con un protocollo e un'architettura distinti dal collasso preliminare sopra citato, costituisce un'ulteriore conferma indipendente della difficoltà di ottimizzare circuiti VQC con metodi basati su gradiente in questo regime, a supporto della scelta di NFT per la pipeline principale.

3.6 Ablation obbligatoria e metriche

Per ciascuna combinazione (compressore, d , seed) viene addestrato anche un classificatore Logistic Regression direttamente sul vettore compresso, con lo stesso split e medesimo protocollo di valutazione del benchmark quantistico, sull'intero training set canonico. Le metriche riportate, comuni a tutta la pipeline, sono: macro-F1, macro-AUROC (schema one-vs-rest), balanced accuracy [13] ed Expected Calibration Error (ECE, 15 bin uniformi, norma L_1 , confidenza top-1).

3.7 Baseline classica few-shot a parità di regime dati con il VQC

Oltre alla no-quantum ablation (che usa l'intero training set), è stato addestrato un secondo riferimento classico — un MLP a un hidden layer (32 unità, ReLU, dropout 0,3), ottimizzato con Adam (lr = 0,01, weight decay 10^{-4} , fino a 100 epoche, early stopping patience 15) — nello stesso identico regime dati del VQC: un singolo batch bilanciato di 32 campioni (8 per classe). A differenza del VQC, però, questo batch viene estratto *una sola volta prima del training loop* e riusato identico per tutte le epoche, mentre il VQC ricampiona un batch fresco ad ogni epoca da un pool di 256 campioni (Sezione 3.5). Questa differenza — non deliberata in origine, emersa durante lo sviluppo — si rivela un fattore esplicativo rilevante in Sezione 5.6.

4 Risultati Sperimentali

4.1 Ablation no-quantum: Logistic Regression sulle feature compresse

La Tabella 1 riporta le medie sui tre seed di controllo per ciascuna combinazione (compressore, d), per la no-quantum ablation obbligatoria (Logistic Regression, come richiesto dal documento di progetto).

Table 1: Macro-F1 (Logistic Regression), media su 3 seed.

d	B1 (PCA)	B2 (AE)	B3 (AE reg.)
32	0.8660	0.8612	0.8600
16	0.8654	0.8618	0.8541
8	0.8654	0.8552	0.8377
4	0.8645	0.8197	0.7426

Table 2: Macro-AUROC (one-vs-rest), media su 3 seed.

d	B1 (PCA)	B2 (AE)	B3 (AE reg.)
32	0.9752	0.9752	0.9730
16	0.9744	0.9748	0.9710
8	0.9738	0.9730	0.9665
4	0.9739	0.9633	0.9487

Selezione del comparatore primario

Come richiesto dal documento di progetto, è stato eseguito uno screening a tre vie (Logistic Regression, MLP a un hidden layer, RBF-SVM) con selezione basata esclusivamente su validation set, macro-F1 media su tutte le combinazioni e sui 3 seed. Il comparatore selezionato è l'**MLP** (val macro-F1 media 0,9845, contro 0,9755 di RBF-SVM e 0,9745 di Logistic Regression). Questa selezione è indipendente e aggiuntiva rispetto alla no-quantum ablation obbligatoria (Tabelle 1–4), che il documento fissa esplicitamente come coincidente con la Logistic Regression; il dettaglio completo dello screening a tre vie è disponibile in `artifacts/sweep/team_b_screening.csv`.

4.2 Pipeline quantistica completa (VQC con data re-uploading)

La Tabella 5 riporta, per ciascuna combinazione (compressore, d), la macro-F1 di test media e deviazione standard sui 3 seed, al checkpoint di miglior validation macro-F1. Il gap medio tra validation e test macro-F1 è di soli 0,032 punti su tutte le 36 combinazioni — sostanzialmente più contenuto rispetto a configurazioni preliminari della pipeline (non conformi), dove il validation set condivideva la distribuzione di pre-training del backbone e produceva una stima sistematicamente ottimistica.

La media generale sulle 36 combinazioni è 0,484 (deviazione standard 0,171, minimo 0,136, massimo 0,788), contro $\sim 0,86$ della Logistic Regression (Tabella 1): un divario sostanziale ma un modello nel complesso funzionante, non collassato. La tabella completa a livello di singolo seed è disponibile in `experiments/production_summary.csv`.

4.3 Baseline classica few-shot

La Tabella 6 riporta il confronto diretto, a parità di regime dati (32 campioni di training), tra l'MLP few-shot (Sezione 3.7) e il VQC.

Il pattern è netto e sistematico: su B1 e B2 l'MLP few-shot supera il VQC su ogni dimensione (delta da +0,11 a +0,48); su B3 il pattern si inverte comple-

Table 3: Balanced accuracy, media su 3 seed.

d	B1 (PCA)	B2 (AE)	B3 (AE reg.)
32	0.8466	0.8383	0.8359
16	0.8458	0.8396	0.8275
8	0.8455	0.8345	0.8079
4	0.8447	0.8011	0.7173

Table 4: Expected Calibration Error ($\downarrow$ migliore), 15 bin uniformi, norma L_1 .

d	B1 (PCA)	B2 (AE)	B3 (AE reg.)
32	0.0685	0.0556	0.0390
16	0.0686	0.0531	0.0244
8	0.0683	0.0490	0.0154
4	0.0682	0.0442	0.0331

tamente, con il VQC che supera l'MLP few-shot su tutte e quattro le dimensioni (delta da $-0,20$ a $-0,34$). Questa inversione è discussa in dettaglio in Sezione 5.6.

4.4 Sweep few-shot

La Tabella 7 riporta macro-F1 di LR e VQC su frazioni decrescenti del training set (25%, 10%, 5%), per $d \in \{8, 4\}$, seed = 11. Il VQC usa la stessa architettura del benchmark principale (Sezione 3.4–3.5); lo scaler è rifittato sul solo subset few-shot, mentre validation e test restano i set fissi standard, come richiesto dal protocollo (il few-shot varia solo il training set).

Due osservazioni distinte emergono. **La LR degrada in modo marcatamente diverso tra compressori:** per B1 e B2 la macro-F1 resta sostanzialmente piatta anche al 5% dei dati (variazione $\leq 0,005$ per B1, $\leq 0,004$ per B2, rispetto al valore full-train di Tabella 1), mentre per B3 il calo è sostanziale ($-0,126$ a $d = 4$, $-0,151$ a $d = 8$, dal full-train al 5%) — un'ulteriore conferma, indipendente, che le rappresentazioni di B3 richiedano più dati per essere sfruttate in modo affidabile, coerente con quanto osservato in Sezione 5.1.

Il VQC non mostra un andamento monotono rispetto alla frazione di dati: in 4 delle 6 combinazioni (compressore, d), la macro-F1 di test *aumenta* quando la frazione di training disponibile *diminuisce* (es. B2 $d = 4$: $0,347 \rightarrow 0,583$ dal 25% al 5%). Con un solo seed disponibile per questo sweep, non è possibile distinguere un effetto reale da variabilità di ottimizzazione — e data l'instabilità di NFT già documentata in Sezione 5.4, quest'ultima è l'ipotesi più parsimoniosa. Questo risultato è riportato come osservazione, non come effetto causale accertato: una conferma richiederebbe più seed, non disponibili in questa consegna.

5 Discussione dei Risultati

5.1 I compressori divergono a bassa dimensione latente, non a dimensione piena

A $d = 32$ e $d = 16$ i tre compressori sono quasi equivalenti (differenza di macro-F1 $\leq 0,012$). Il quadro

Table 5: VQC: macro-F1 di test, media $\pm$ deviazione standard su 3 seed.

d	B1 (PCA)	B2 (AE)	B3 (AE reg.)
32	$0,363 \pm 0,054$	$0,692 \pm 0,094$	$0,662 \pm 0,045$
16	$0,420 \pm 0,115$	$0,652 \pm 0,061$	$0,526 \pm 0,043$
8	$0,413 \pm 0,129$	$0,343 \pm 0,070$	$0,366 \pm 0,076$
4	$0,732 \pm 0,026$	$0,327 \pm 0,183$	$0,316 \pm 0,037$
media	0,482	0,504	0,467

Table 6: MLP few-shot (batch fisso, Adam) vs VQC (batch ricampionato, NFT): macro-F1 di test, media su 3 seed, stesso regime dati.

Comp.	d	MLP few-shot	VQC	Δ (MLP-VQC)
B1	32	0,8377	0,3625	+0,4752
B1	16	0,8368	0,4196	+0,4172
B1	8	0,8445	0,4132	+0,4313
B1	4	0,8453	0,7322	+0,1131
B2	32	0,8429	0,6921	+0,1508
B2	16	0,8161	0,6524	+0,1637
B2	8	0,6851	0,3431	+0,3420
B2	4	0,6400	0,3267	+0,3133
B3	32	0,3876	0,6617	-0,2741
B3	16	0,1903	0,5262	-0,3359
B3	8	0,1210	0,3657	-0,2447
B3	4	0,1111	0,3159	-0,2048

cambia però nettamente a dimensioni ridotte: a $d = 4$, B1 mantiene una macro-F1 di 0,8645, B2 scende a 0,8197 e B3 crolla a 0,7426 — un divario di oltre 12 punti tra B1 e B3, con una deviazione standard sui seed che passa da $\sim 0,001$ a $d = 32$ a $0,045$ a $d = 4$ per B3. Lo stesso pattern, più attenuato, emerge in balanced accuracy (0,8447 vs 0,7173 a $d = 4$) e macro-AUROC. Questo indica che la degradazione di B3 a bassa dimensione non è un artefatto dell’ottimizzazione del VQC (Sezione 5.5): è già presente nelle feature compresse stesse, misurata con un semplice classificatore lineare. È inoltre lo stesso seed (17) a produrre il valore più basso sia nella no-quantum ablation (0,697 per B3 a $d = 4$, contro 0,786 e 0,745 degli altri due seed) sia, come discusso in Sezione 5.5, nella pipeline VQC completa — un’evidenza convergente che la causa vada ricercata nella compressione B3 a quella specifica combinazione di seed e dimensione, non nel classificatore a valle, quale esso sia.

5.2 Un trade-off di calibrazione emerge, più marcato a bassa dimensione

Osservando l’ECE (Tabella 4), B3 ottiene un errore di calibrazione sistematicamente inferiore a B1 su ogni dimensione, con il divario più ampio a $d = 8$ (0,0154 contro 0,0683, quasi $5\times$ inferiore) e ancora sostanziale a $d = 4$ (0,0331 contro 0,0682) nonostante il crollo di macro-F1 discusso sopra. Questo è coerente con la penalità di sparsità L_1 di B3: forzando molte attivazioni latenti verso valori vicini a zero, il classificatore a valle riceve una rappresentazione meno ridondante, che si

Table 7: Sweep few-shot: macro-F1 di test, seed= 11.

Comp.	d	Fraz.	LR	VQC
B1	8	25%	0,8664	0,4647
		10%	0,8674	0,5484
		5%	0,8657	0,6571
B1	4	25%	0,8636	0,6908
		10%	0,8631	0,7726
		5%	0,8592	0,6849
B2	8	25%	0,8566	0,4982
		10%	0,8542	0,3788
		5%	0,8513	0,4663
B2	4	25%	0,8289	0,3466
		10%	0,8223	0,5535
		5%	0,8158	0,5828
B3	8	25%	0,8091	0,3053
		10%	0,7581	0,3080
		5%	0,6864	0,3238
B3	4	25%	0,7287	0,3530
		10%	0,6711	0,3738
		5%	0,6164	0,4493

traduce in probabilità meno estreme e quindi meglio calibrate, indipendentemente dal fatto che il potere discriminativo grezzo (F1) sia più alto o più basso. In un contesto clinico come la classificazione di patologie retiniche da OCT, dove la fiducia associata a una predizione ha un peso specifico nella pratica decisionale, questo trade-off tra F1 grezzo e calibrazione — e la sua dipendenza da d — meritano considerazione esplicita nella scelta del compressore e della dimensione latente insieme, non separatamente.

5.3 Pesi condivisi vs indipendenti nel circuito re-uploading

Durante lo sviluppo è stata esplorata una variante del circuito con pesi variazionali condivisi tra i cicli di re-uploading (stesso set di parametri riusato ad ogni blocco, in linea con lo schema originale di Pérez-Salinas et al. [1]), motivata dal tentativo di contenere la crescita del numero di parametri trainabili con l’aumentare di d . Un test diagnostico dedicato ha confermato che il numero di parametri effettivamente presenti nel circuito corrispondeva esattamente a quello atteso, escludendo un errore di implementazione. Empiricamente, tuttavia, questa variante ha prodotto risultati sistematicamente peggiori rispetto alla versione a pesi indipendenti, con macro-F1 di test talvolta sotto il livello di un classificatore casuale (0,25 per un problema a 4 classi). Una possibile spiegazione è che il vincolo di riutilizzare lo stesso piccolo insieme di parametri su blocchi di feature statisticamente eterogenei — specialmente alle dimensioni latenti più alte, dove il numero di cicli è maggiore — comprime eccessivamente la capacità del circuito di adattarsi a segmenti diversi del vettore compresso. Questo risultato negativo, per quanto non risolutivo, costituisce un’evidenza empirica rilevante sull’interazione tra profondità del circuito, condivisione dei parametri e allen-

abilità con ottimizzatori gradient-free, ed è riportato per trasparenza metodologica.

5.4 Difficoltà di ottimizzazione con NFT su circuiti re-uploading profondi

L'analisi epoca per epoca del training ha rivelato un pattern di convergenza non monotona: la macro-F1 di validazione tipicamente oscilla per diverse epoche prima di un miglioramento improvviso, anziché seguire un andamento gradualmente crescente. In alcuni casi isolati il modello non è uscito da un collasso su un sottoinsieme delle quattro classi per l'intera durata del training. Questo comportamento è coerente con un landscape di ottimizzazione più rugoso rispetto a un singolo blocco encoding-ansatz: con pesi indipendenti per ciclo, il numero di parametri cresce proporzionalmente al numero di cicli di re-uploading, e NFT — pur efficiente nello sfruttare la struttura sinusoidale di ciascun parametro preso singolarmente — non modella esplicitamente le interazioni tra cicli sequenziali, rendendo la ricerca di un ottimo congiunto più difficile all'aumentare della profondità.

È stata inoltre verificata empiricamente, tramite un test diagnostico dedicato che ha isolato la sola pipeline di scaling e padding delle feature (bypassando il circuito quantistico e sostituendolo con una Logistic Regression sulle stesse feature trasformate), l'assenza di anomalie nella trasformazione dei dati: la differenza di macro-F1 tra feature grezze e feature scalate/paddate è risultata trascurabile ($< 0,01$ punti in valore assoluto, mediamente positiva) su tutte le 36 combinazioni testate. Questo permette di attribuire con ragionevole sicurezza le difficoltà osservate all'ottimizzazione del circuito quantistico, e non a un artefatto della pipeline di pre-elaborazione.

5.5 Confronto diretto VQC vs Logistic Regression e conferma del pattern compressore-dimensione

Il divario tra VQC e Logistic Regression è sostanziale su ogni combinazione: la media generale del VQC (0,484) resta $\sim 0,38$ punti sotto quella della LR ($\sim 0,85$), e anche la combinazione migliore del VQC (B2, $d = 32$, 0,788 medio) non raggiunge il valore più basso osservato per la LR in nessuna combinazione — incluso il caso più debole della LR stessa, B3 a $d = 4$ (0,743, comunque $\sim 0,43$ punti sopra il VQC sulla stessa combinazione, 0,316). Anche nella combinazione in cui la qualità delle feature compresse è essa stessa più bassa (Sezione 5.1), il collo di bottiglia resta l'ottimizzazione del circuito quantistico, non la compressione a monte.

Chiarimento preliminare, necessario prima di procedere. Per costruzione della PCA, le componenti sono autovettori della matrice di covarianza ordinati per varianza decrescente: le prime 4 componenti di una PCA fittata con $d = 32$ sono *identiche* alle 4 componenti di una PCA fittata direttamente con $d = 4$ sugli stessi dati (proprietà di annidamento). $d = 32$ contiene quindi, per costruzione matematica, almeno tutta l'informazione di $d = 4$, più 28 componenti aggiuntive: non può esistere una configurazione

in cui $d = 4$ porti più informazione di $d = 32$ per B1. Questo è confermato empiricamente dalla Tabella 1: con Logistic Regression, $d = 32$ ottiene macro-F1 0,8660 contro 0,8645 di $d = 4$ — leggermente *migliore*, come atteso quando un classificatore riesce a sfruttare l'informazione disponibile. Il pattern opposto osservato con il VQC (paragrafo seguente) misura quindi *quanta di questa informazione il circuito, con il budget di ottimizzazione disponibile, riesce a estrarre* — non quanta informazione è presente nei dati. Sono due grandezze distinte, e il paragrafo seguente non va interpretato come un'affermazione sulla seconda.

Il confronto per dimensione conferma nettamente l'ipotesi formulata nelle fasi esplorative: B1 (PCA) ottiene la sua migliore macro-F1 a $d = 4$ (0,732) e la peggiore a $d = 32$ (0,363) — un ordinamento invertito rispetto a B2 e B3, che ottengono invece il proprio massimo a $d = 32$ (0,692 e 0,662 rispettivamente) e il minimo a $d = 4$ (0,327 e 0,316). Come chiarito sopra, per B1 questo non riflette una differenza di informazione disponibile, ma di *estraibilità*: il primo blocco di re-uploading (le prime 4 componenti, equivalente all'intero input per $d = 4$) concentra già la maggior parte del segnale utile, mentre i cicli aggiuntivi necessari per d più alte — pur portando informazione genuina, per la proprietà di annidamento sopra — aumentano la profondità del circuito (fino a 8 cicli indipendenti a $d = 32$, Sezione 3.4) oltre quanto NFT riesce a ottimizzare in modo affidabile (Sezione 5.4), diluendo nella pratica il segnale utile del primo blocco invece di aggiungervisi. Le rappresentazioni di B2 e B3, non ordinate per importanza (non esiste per un autoencoder una proprietà di annidamento analoga a quella della PCA), non hanno un blocco iniziale già sufficiente da solo: ogni ciclo aggiuntivo introduce segnale che il modello non può recuperare altrove, e il guadagno di informazione per ciclo compensa il costo di ottimizzazione più alto a d elevate. Per B1 vale l'opposto: il guadagno marginale di informazione dei cicli tardivi (componenti PCA a bassa varianza) è ridotto, e il costo di ottimizzazione aggiuntivo prevale. È lo stesso meccanismo — bilanciamento tra guadagno di informazione per ciclo e costo di ottimizzazione per ciclo — a produrre pattern opposti nei due casi, non un'incoerenza tra compressori. La correlazione negativa osservata tra train loss e test macro-F1 su tutte le 36 combinazioni ($r = -0,76$) è coerente con questa lettura: le combinazioni in cui NFT converge meglio sul batch di training sono sistematicamente quelle che generalizzano meglio, indicando che il fattore limitante è l'ottimizzazione stessa e non una disconnessione patologica tra fit e generalizzazione.

5.6 L'inversione B1/B2 vs B3 nel confronto con l'MLP few-shot

Il risultato più inatteso di questo lavoro emerge dal confronto a parità di regime dati (Tabella 6, Sezione 5.3). Su B1 e B2 l'MLP few-shot supera nettamente il VQC su ogni dimensione — atteso, poiché Adam con gradiente esatto su un problema di classificazione così piccolo (32 campioni) converge tipicamente meglio di un ottimizzatore gradient-free come

NFT. Su B3, tuttavia, il pattern si inverte completamente: il VQC supera l'MLP few-shot su tutte e quattro le dimensioni, con un margine che arriva a 0,336 punti di macro-F1 a $d = 16$.

L'analisi del `best_loss` (la loss di training raggiunta dall'MLP sul proprio batch fisso) chiarisce la natura del fenomeno. Per B1, la loss media è 0,021 (minimo 0,0004, massimo 0,113): l'MLP fitta quasi perfettamente il proprio batch di 32 campioni, un comportamento di memorizzazione atteso data la capacità del modello (292–1188 parametri a seconda di d) rispetto alla dimensione del batch. Per B3, invece, la loss media è 1,108 — vicinissima a $\ln 4 \approx 1,386$, il valore atteso da un classificatore che assegna probabilità uniforme alle 4 classi. In 7 combinazioni su 12, la loss di B3 supera 1,25: l'MLP non riesce a fittare nemmeno il proprio piccolissimo batch di training, non solo a generalizzare da esso.

Questo è confermato in modo indipendente dal gap tra validation e test macro-F1: per B1 il gap medio è 0,120 (la validation, proveniente dallo stesso pool del training, riflette parzialmente la memorizzazione del batch fisso), mentre per B3 il gap medio è 0,0025 — praticamente nullo, perché il modello non ha né una prestazione di validation né di test da cui possa emergere un gap: fallisce ugualmente su entrambe. Il problema con B3, quindi, non è un fallimento di generalizzazione dopo un buon fit (overfitting classico), ma un fallimento di ottimizzazione sul batch stesso.

La spiegazione più plausibile risiede in una differenza architetturale tra i due protocolli di training, non deliberata in origine ma osservata durante lo sviluppo: l'MLP few-shot usa un *singolo batch fisso*, estratto una sola volta prima delle 100 epoche di training (Sezione 3.7), mentre il VQC ricampiona un batch fresco da un pool di 256 campioni ad ogni epoca (Sezione 3.5). Le attivazioni latenti di B3 sono vincolate in $[0, 1]$ dalla sigmoide e spinte verso zero dalla penalità di sparsità L_1 : è plausibile che, per un singolo campionamento sfortunato di 32 esempi, molte dimensioni risultino pressoché costanti (vicine a zero) attraverso l'intero batch, producendo gradienti quasi nulli per i pesi ad esse connesse e bloccando l'ottimizzazione di Adam in una regione piatta della funzione di perdita — un fenomeno concettualmente analogo, a livello classico, ai plateau di ottimizzazione discussi per il VQC in Sezione 5.4. Il VQC, esposto a un campione diverso ad ogni epoca, ha più occasioni di incontrare batch meno degeneri, un effetto di regolarizzazione implicita che qui si rivela decisivo. Questa spiegazione è coerente con tutte le evidenze disponibili ma non è stata isolata con un esperimento controllato dedicato (ad esempio, ripetendo l'addestramento dell'MLP few-shot con ricampionamento ad ogni epoca, a parità di tutto il resto); è lasciata come verifica diretta a lavoro futuro.

6 Conclusioni

Questo lavoro ha confrontato tre strategie di compressione degli embedding (PCA, autoencoder vanilla,

autoencoder regolarizzato con sparsità) all'interno di una pipeline ibrida classico-quantistica per la classificazione di immagini OCT, mantenendo fissi encoding quantistico, ansatz, metriche e protocollo sperimentale come richiesto dal disegno multi-team del progetto. L'ablation classica obbligatoria mostra che i tre compressor sono equivalenti a dimensione latente piena, ma divergono nettamente a dimensioni ridotte — in particolare il compressore regolarizzato, che perde oltre 12 punti di macro-F1 tra $d = 32$ e $d = 4$ — ed emerge un trade-off di calibrazione a favore dello stesso compressore, rilevante in un dominio applicativo clinico.

Il percorso di sviluppo della pipeline quantistica ha richiesto un lavoro sostanziale di verifica di conformità rispetto alla specifica di progetto — in particolare sullo schema di data re-uploading, mai banale da implementare correttamente quando la dimensione compressa eccede il numero di qubit disponibili — e ha prodotto un'evidenza empirica non banale sulla difficoltà di ottimizzare circuiti re-uploading profondi con un ottimizzatore gradient-free come NFT, incluso un confronto esplicito e documentato tra schema a pesi condivisi e indipendenti tra i cicli.

Sul piano quantitativo, il VQC raggiunge una macro-F1 di test media di 0,484 contro $\sim 0,86$ della Logistic Regression: un divario sostanziale, ma accompagnato da un comportamento stabile e interpretabile, non da un collasso del modello. Il pattern di interazione compressore-dimensione — B1 favorito da d basse, B2 e B3 da d alte — si conferma nettamente e trova una spiegazione coerente nella struttura ordinata per varianza di PCA contro quella non ordinata degli autoencoder, suggerendo che la scelta della dimensione latente ottimale per un VQC con re-uploading debba tenere conto esplicitamente di questa interazione, e non essere trattata come un iperparametro indipendente dal compressore a monte.

Come limitazione principale, il presente lavoro non esclude che ottimizzatori alternativi (o un budget di valutazioni ulteriormente scalato) possano mitigare l'instabilità di convergenza osservata; un'esplorazione sistematica di questo aspetto, così come uno studio più esteso della presenza di barren plateau [11] in questo specifico regime di re-uploading multi-ciclo, sono lasciati a lavoro futuro.

References

- [1] A. Pérez-Salinas, A. Cervera-Lierta, E. Gil-Fuster, J. I. Latorre. *Data re-uploading for a universal quantum classifier*. Quantum, 4:226, 2020.
- [2] J. Yang, R. Shi, D. Wei, Z. Liu, L. Zhao, B. Ke, H. Pfister, B. Ni. *MedMNIST v2: A Large-Scale Lightweight Benchmark for 2D and 3D Biomedical Image Classification*. Scientific Data, 10:41, 2023.
- [3] K. He, X. Zhang, S. Ren, J. Sun. *Deep Residual Learning for Image Recognition*. Proceedings

- of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778, 2016.
- [4] H. Hotelling. *Analysis of a Complex of Statistical Variables into Principal Components*. Journal of Educational Psychology, 24(6):417–441, 1933.
 - [5] G. E. Hinton, R. R. Salakhutdinov. *Reducing the Dimensionality of Data with Neural Networks*. Science, 313(5786):504–507, 2006.
 - [6] M. Benedetti, E. Lloyd, S. Sack, M. Fiorentini. *Parameterized Quantum Circuits as Machine Learning Models*. Quantum Science and Technology, 4(4):043001, 2019.
 - [7] M. Cerezo, A. Arrasmith, R. Babbush, et al. *Variational Quantum Algorithms*. Nature Reviews Physics, 3:625–644, 2021.
 - [8] M. Schuld, R. Sweke, J. J. Meyer. *Effect of Data Encoding on the Expressive Power of Variational Quantum Machine Learning Models*. Physical Review A, 103(3):032430, 2021.
 - [9] R. S. Gupta, C. E. Wood, T. Engstrom, J. D. Pole, S. Shrapnel. *A Systematic Review of Quantum Machine Learning for Digital Health*. npj Digital Medicine, 8:237, 2025.
 - [10] G. Singh, H. Jin, K. M. Merz Jr. *Benchmarking MedMNIST Dataset on Real Quantum Hardware*. Scientific Reports, 16:9017, 2026.
 - [11] J. R. McClean, S. Boixo, V. N. Smelyanskiy, R. Babbush, H. Neven. *Barren Plateaus in Quantum Neural Network Training Landscapes*. Nature Communications, 9:4812, 2018.
 - [12] Qiskit Documentation Team. *Qiskit Circuit Library: RealAmplitudes*. <https://qiskit.org>.
 - [13] scikit-learn Documentation Team. *Model Evaluation: roc_auc_score, f1_score, balanced_accuracy_score*. <https://scikit-learn.org>.
 - [14] Documento di progetto FVAB. *Benchmark Quantum-Classical su Embedding OCT Compressi*, handout operativo condiviso, versione fornita dal docente del corso.